

PROJECT

AI 기반 고객 이탈 분석 프로젝트

SKN 34기 2차 프로젝트 2팀

PROJECT

목차

1 팀 소개

2 프로젝트 개요

3 프로젝트 진행 일정

4 기술 스택

5 프로젝트 구조

6 실행 방법

7 데이터 전처리 결과

8 인공지능 학습 결과

9 학습된 인공지능 모델

10 고객 이탈 방지 전략

11 서비스 주요 기능

12 트리블슈팅

13 한줄 회고

1. 팀 소개

팀명: 재미짐옥

이름	담당
이현준	Streamlit UI 구현 · 군집 분석
정예린	데이터 수집 · 분류 모델 분석
김재현	분류 모델 · 군집 분석
김태운	회귀 · 분류 · 군집 분석

2. 프로젝트 개요

프로젝트 명	헬스장 고객 이용 특성 기반 이탈 분석 및 고객군 예측 시스템
프로젝트 소개	이용 기간·연령·방문 빈도·계약 기간 등을 분석하여 고객군별 이탈률과 이탈 특성을 파악하고, 분석 결과를 Streamlit으로 시각화 한 프로젝트입니다
필요성	일반적으로 헬스장 회원의 이탈은 운동에 대한 흥미 저하나 운동 의욕 감소 때문이라고 생각하기 쉽습니다. 하지만 꾸준히 이용하거나 방문 빈도가 높은 고객도 이탈할 수 있습니다. 따라서 다양한 고객 특성을 분석하여 이탈이 높은 고객군과 주요 이탈 패턴을 파악하고자 합니다.
프로젝트 목표	고객 데이터를 분석하여 이용 특성과 이탈 패턴을 파악하고, 고객군별 이탈 위험을 분석해 Streamlit으로 시각화 및 인사이트를 도출하는게 목표 입니다.

3. 프로젝트 진행 일정

- | | |
|----------------------------------|---------------------------------|
| 01 7/21~7/24 데이터 수집 | 05 8/2 예측 페이지 구현 |
| 02 7/25~7/26 아키텍처 및 UI 설계 | 06 8/3~8/4 분석 레포트 작성 |
| 03 7/27~7/29 데이터 분석 | 07 8/5 README 작성 및 최종 점검 |
| 04 7/30~8/1 모델 학습 및 고도화 | 08 8/6 프로젝트 발표 |

4. 기술 스택

언어	Python 3.12
데이터 분석	Pndas 3.0.3, NumPy 2.5.1
머신러닝	Scikit-learn 1.9.0, XGBoost 3.3.0, Optuna 4.9.0
시각화	Matplotlib 3.11.0, Seaborn 0.13.2, Plotly 6.9.0, Altair 6.2.2
웹 애플리케이션	Streamlit1.60.0
협업	Git, GitHub

5. 프로젝트 구조

```
project_2nd/
├── .streamlit/      # Streamlit 환경 및 화면 설정
├── data/            # 분석에 사용되는 원본 데이터
├── docs/            # 프로젝트 문서 자료
├── models/          # 학습된 모델 및 예측에 필요한 파일
│   ├── analysis1/
│   ├── analysis2/
│   ├── analysis3/
│   └── analysis4/
├── notebooks/       # 분석 및 모델링 과정의 Jupyter Notebook
│   ├── analysis1.ipynb
│   ├── analysis2.ipynb
│   ├── analysis3.ipynb
│   └── analysis4.ipynb
├── pages/           # Streamlit 페이지
│   ├── dashboard.py # 전체 분석 결과 대시보드
│   ├── analysis1~4.py # 팀원별 분석 결과 페이지
│   └── predict.py    # 샘플 데이터 예측 페이지
├── reports/         # 분석 및 프로젝트 결과 보고서
│   ├── images/       # 분석별 시각화 결과 이미지
│   │   ├── analysis1~4/ # 각 분석별 그래프 및 결과 이미지
│   ├── analysis1~4_report.md # 팀원별 분석 보고서
│   └── final_report.md # 최종 프로젝트 보고서
├── src/             # 데이터 분석 및 모델링 코드
│   ├── analysis1~4/   # 분석별 EDA·전처리·학습·평가·예측 모듈
│   └── common/        # 공통 데이터 로딩 및 설정
├── app.py           # Streamlit 실행 및 페이지 구성
├── README.md         # 프로젝트 소개 및 문서
├── requirements.txt  # 프로젝트 의존성 패키지
└── .gitignore        # Git 관리 제외 파일 설정
```

6. 실행 방법

1. 권장 (uv + pyproject.toml)

uv 설치 (최초 1회)
pip install uv

의존성 설치 및 가상환경 생성
uv sync

Streamlit 실행
uv run streamlit run app.py

uv + requirements.txt

uv 설치 (최초 1회)
pip install uv

가상환경 생성
uv venv

의존성 설치
uv pip install -r requirements.txt

Streamlit 실행
uv run streamlit run app.py

Python venv + requirements.txt

가상환경 생성
python -m venv .venv

가상환경 활성화
.venv\Scripts\activate # Windows
source .venv/bin/activate # macOS / Linux

의존성 설치
pip install -r requirements.txt

Streamlit 실행
streamlit run app.py

7. 데이터 전처리 결과

데이터 출처 : kaggle

4,000명 × 14개 변수 사용

결측치 및 중복 데이터 없음

전체 이탈률 26.5%

모든 데이터가 수치형으로 구성되어 별도 인코딩 불필요

EDA와 통계 검증을 통해 이탈과 관련성이 낮은 변수 제외

Train/Test = 8:2, stratify를 적용하여 이탈 비율 유지



변수 간 높은 다중공선성을 확인했으나 트리 기반 모델의 특성을 고려하여 변수제거 없이 진행

다중공선성이 높은 변수는 파생변수로 대체하여 모델 안정성 확보

고객 특성을 기반으로 K-Means 군집 분석을 수행


군집 분석은 고객의 특성을 파악하고 고객 세그먼트 분석에 활용

8. 인공지능 학습 결과




Lifetime(가입기간)이 두 모델 모두에서 가장 중요한 변수로 나타남
최근 수업 참여 빈도·연령이 뒤를 이었으며, 이용 행동 패턴이 이탈 예측에 중요한
것으로 확인됨

8. 인공지능 학습 결과




계약·이용 기간(Lifetime, Contract_period)과 방문 빈도가 이탈 예측에 가장 큰 영향을 미침
피쳐 중요도 결과가 상관관계 분석 결과와 일치함

8. 인공지능 학습 결과



고도화 모델에서 최적 군집 수가 K=3으로 선정되었다.
 0번 클러스터: 이용 기간이 긴 VIP 회원군
 1번 클러스터: 계약 기간이 긴 장기 계약 회원군
 2번 클러스터: 이용 기간과 방문 빈도가 낮은 이탈 위험 회원군



K-Means를 이용해 3개 고객군으로 분류
 고객군은 이용 특성에 따라 나누고, 이탈 위험 등급은 예측 확률로 판단하여 고객별 특성과 이탈 위험을 쉽게 파악할 수 있도록 함

9. 학습된 인공지능 모델 요약

구분	기본 모델	고도화 모델
전처리	StandardScaler	RobustScaler
모델	K-Means	K-Means
최적 K	4	3
Test Silhouette	0.2669	0.313

최종 선정 모델: RobustScaler + K-Means (K=3)
주요 특징: 기본 모델 대비 군집 품질 향상(Silhouette Score 0.3130). 이용

모델	구분	Accuracy	Recall	F1 Score	ROC-AUC
Decision Tree	고도화 전	0.9062	0.8066	0.8201	0.8744
Decision Tree	고도화 후	0.9112	0.816	0.8297	0.9381
Random Forest	고도화 전	0.9275	0.8349	0.8592	0.9676
Random Forest	고도화 후	0.925	0.8208	0.8529	0.9694

최종 채택 모델: Random Forest (Advanced)
하이퍼파라미터: max_depth=10, max_features='sqrt', n_estimators=300
Test 성능: Accuracy 0.9250 / Recall 0.8208 / F1 0.8529 / ROC-AUC 0.9694

9. 학습된 인공지능 모델 요약

모델	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.9269	0.8831	0.8351	0.8584	0.9755
Random Forest	0.9159	0.8624	0.8139	0.8371	0.9708
Gradient Boosting	0.9306	0.8965	0.8351	0.8647	0.9785
XGBoost	0.9337	0.8952	0.8504	0.872	0.9773

XGBoost가 F1 0.8720, 재현율 0.8504로 가장 우수하여 고도화 모델로 선정
 SMOTE 적용 시 재현율은 향상되지만 정밀도와 F1이 소폭 감소하여 SMOTE 미적용으로 결정
 RandomizedSearchCV로 튜닝 후 F1 0.8835까지 개선하여 최종 모델로 선정

구성	모델	ROC-AUC	F1	Recall	Precision	임계값
S1/파생	xgb 기본	0.9849	0.9178	0.9057	0.9302	0.5
	xgb 고도화	0.9878	0.9167	0.9132	0.9202	0.3943
	변화	0.0029	-0.0011	0.0075	-0.01	
S2/원본	logreg 기본	0.9535	0.7922	0.7698	0.816	0.5
	logreg 고도화	0.9535	0.8007	0.8113	0.7904	0.4021
	변화	0	0.0085	0.0415	-0.0256	

Optuna와 임계값을 교차검증으로 최적화하여 모델 성능을 개선
 AUC 변화 없이 F1·Recall은 향상되었으나, Recall 상승의 대가로 Precision은 감소
 두 모델 모두 기본 임계값 0.5보다 낮은 값이 최적 → 이탈 고객을 더 잘 탐지할 수 있도록 조정
 이탈 고객을 놓치지 않는 Recall 중심으로 임계값을 최적화

10. 고객 이탈 방지 전략

최종 분석	가입 초기·단기 계약·낮은 방문 빈도·27세 전후 고객의 이탈률이 높게 나타나, 위험 고객을 사전에 관리하고 고객 특성에 맞는 맞춤형 관리가 필요함 (27세 전후 고객은 사회초년생 또는 사회 경력이 적은 사람으로 보이며 그로인해 생활패턴이 안정적이지 않아 이탈이 많아 보임)
개인 헬스장	1. 신규 회원 밀착 관리로 초기 적응 지원 2. 출석 감소 회원 관리로 이탈 예방 3. 친구 추천 혜택으로 기존 회원 유지 및 신규 회원 유입
체인 헬스장	1. 콜라보 마케팅으로 신규 고객 유입 및 관심도 확대 2. 장기·고빈도 회원 혜택으로 고객 유지 강화 3. 기업·지역 제휴 및 추천 프로그램으로 신규 회원 확보
공통 대책	1. 사회초년생 맞춤형 유연한 계약으로 부담 완화 2. 복귀 회원 혜택으로 재방문 유도 3. 장기 계약 할인·혜택으로 회원 유지 강화

11. 서비스 주요 기능

<http://localhost:8501>

12. 트러블슈팅

이름	내용
이현준	고도화 과정에서 만들어 놓은 고도화 전처리를 사용안하고 고도화 전에 했던 전처리를 사용해서 고도화를 진행해 계속 같은 값만 나와서 해매다가 결국 원인을 찾아서 정상적으로 고도화를 적용 했다.
정예린	여러 가상환경을 오가며 작업하다 모듈 에러가 발생해, 올바른 가상환경 확인 후 재설치했다.
김재현	깃허브 공동작업에 대한 숙련도 부족 문제로 저장소 연결에 문제가 있었지만 검색 등을 통해 문제를 해결했다.
김태운	기획 단계에서 작업 내용과 관련해 팀과 의견 차이가 있었으나 팀의 의견을 수용하였다.

13. 한줄 회고

이름	내용
이현준	처음 팀장을 맡았고 큰 규모의 프로젝트에 익숙하다 보니 작은 규모의 프로젝트에 대해서 진행하는데 쉽지가 않았다. 팀원들의 만족도를 충족시키지 못해 아쉬움이 있다.
정예린	각자의 역할분담이 잘 나뉘져 큰 문제 없이 프로젝트를 수행했지만, 아이디어를 좀 더 구체화했다면 다양하고 좋은 결과가 나왔을 것 같다.
김재현	머신러닝에 대해 전체적으로 복습할 수 있어서 좋았다. 기능이 좀 더 다양했다면 어땠을까 하는 아쉬움이 남는다.
김태운	더 다양하고 많은 작업이 가능했을 것 같은데 안 해서 아쉽지만 편하긴 했다.

GIT HUB

<https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN34-2nd-1Team>

감사합니다

